Marketplace safety

Alexander, Isac, Sayed, Tobias och Vera

- Företag som driver en marknadsplatsapp
- På appen dyker det upp oseriöst innehåll
- Sara, Product Manage önskar en rangordning över toppfallen som har högst sannolikhet att vara oseriöst innehåll

EDA

- Is_Suspicious korrelation med contains_of_platform(0.14)
  - Tyder på bedragare behöver få kontakt med kunder utanför vår platform och skydd

- Negativ korrelation mellan is_suspicious och account_age_days (-0.10).
  - Då bedragare ofta gör nya konton kommer äldre konton vara mer trovärdiga. Testa att göra konton under 24 timmar mer riskfyllda och högre multiplier

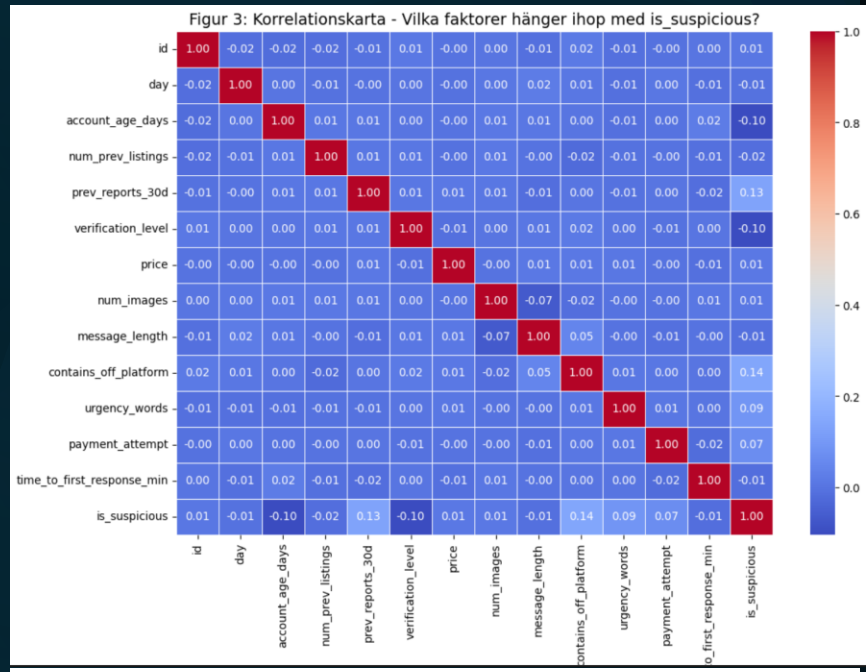

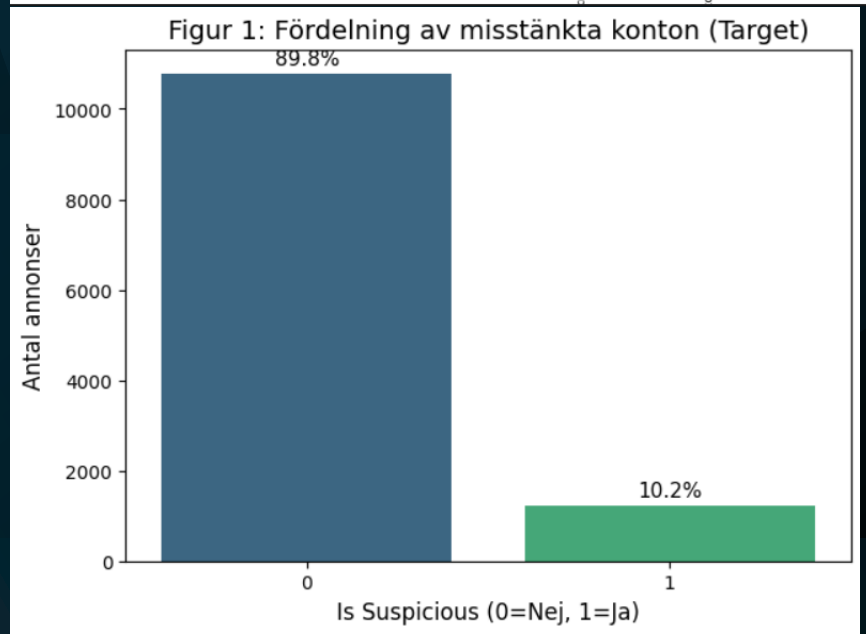

Preprocessing

- Datan delades upp i träningsdata (75%) och testdata (25%) där modellerna tränades enbart på träningsdata för att undvika data läckage
- Pipeline för preprocess:
  - Fylla NaN-värden i numeriska kolumner med median. För kategoriska kolumner fylldes de med den vanligaste variabeln
  - Skala numerisk data
  - OneHotEncoder på kategorisk data
  - Column Transformer

Jämförelsetabell

Modell	Recall (CV)	STD
Baseline DummyClassifier(stratified)	0.101	0.021
LogisticRegression	0.044	0.003
RandomForestClassifier	0.016	0.010

Vald modell - LogisticRegression

- Tolkningsbarhet – Kunden vill enkelt kunna se vad som påverkar risken och hur
  - Om en feature blir större eller mindre, påverkas resultatet positivt eller negativt?
  - RandomForest kan vara mer komplex att tolka
- Vill fånga en stor del misstänkta fall - anpassar modellen efter hög recall
  - Class_weight – stark betoning på minoritetsklassen, medför högre recall men också fler FP.
  - C – försöker undvika överanpassning genom mindre värde på C, ger stabilare koefficienter samt minskar känslighet för brus tillsammans med hög class_weight
  - Kontots ålder, tidigare anmärkningar, verifikationsnivå och om annonsen länkar till en annan platform påverkade riskvärdet mest

Threshold/Prioriteringg

- Vald strategi: Top-X Prioritering
  - Vi har valt Strategi B (Top-X) eftersom vår stakeholder Sara (Product Manager) kräver en rangordnad lista för granskningsteamet.
- Val av X: Vi rekommenderar initialt Topp 5%.
  - Genom att titta på konsekvenserna ser vi att vi får en hög precision i toppen av listan. Det innebär att granskarna inte slösar tid på "falska larm" i onödan. Om teamet får mer resurser kan vi enkelt utöka arbetet till Topp 10% utan att vi behöver byta modell.

```
Om vi granskar TOPP 5% (150 fall):
- Hittar vi 51 av totalt 306 bedrägerier.
- Hit rate (Precision): 34.0% av de granskade var faktiska bedrägerier.
-----------------------------
Om vi granskar TOPP 10% (300 fall):
- Hittar vi 86 av totalt 306 bedrägerier.
- Hit rate (Precision): 28.7% av de granskade var faktiska bedrägerier.
```

Resultat – ny data

- Vi valde att granska top 5% av datan sorterad på högst risk för bedrägeri
  - Resulterade i 100 rader med riskvärden mellan 0.88-0.99 - modellen ger fortsatt mycket höga riskvärden till de mest misstänkta fallen på den nya datan
  - Liknande fall med test/träningsdatan - nya konton med tidigare anmärkningar, länkar till andra platformar och vill att det ska gå fort, samt saknar verifikation

account_age_days	prev_reports_30d	verification_level	contains_off_platform	urgency_words	payment_attempt	risk_score
27.9	2	0	1	0	0	0.987
31.4	1	0	1	1	0	0.983
46.1	1	0	1	0	1	0.976

Risker

- Data drift/förändrat beteende
- Rankingen kan bli mindre träffsäker över tid

Begränsningar

- Modellen kan inte förklara säkert varför något är bedrägeri
- Modellen kan inte upptäcka signaler som inte finns i datan

Nästa steg

- Följa upp modellen på ny data i praktiken
- Uppdatera eller träna om modellen vid förändrade mönster